Finance Agent 方向评审与实验方案

Oct 30, 2026 · @guo3yang

结论与待定决定

建议先改任务和训练设置，暂不跑当前的三臂预算分配对照，也暂不换方向。 当前对照大概率读不出结论：普通 RL 还没被证明能学动，Dev 100 题也测不出这个量级的差异。

本报告用约 8 天的 H100 排期回答三个问题，依次是：RL 能否从强 SFT 继续提升、这个任务里有没有值得分配的预算、我们的方法能否和最近邻拉开差距。每个问题都有事前通过线，没过线时 GPU 直接转去下一项。

需要合作者讨论决定：

- [ ] 是否同意把主问题从“预算怎么分配”调整为先验证“RL 是否有学习增量”
- [ ] 是否同意取消每臂 250 万、总量 1800 万 token 的上限，按本报告排期使用 H100
- [ ] 是否同意准备改造后的任务（工具预算收紧、自然工具故障、多证据决策）
- [ ] 手工阶段权重若输给策略熵或 TRACE 式规则，是否同意直接去掉
- [ ] “实验如何验证方向”一节的通过线是否需要调整，须在看到结果前定稿
- [ ] 目标会议及时间：第三方追踪器估计 ICML 2027 截稿在 2027-01-22 前后（官方尚未公布）

现状与证据边界

强 SFT 已经可用，但还没有任何一次 RL 是从强 SFT 出发、并带着非零 credit 训练的。 所以现有结果既不能说 credit 有效，也不能说它无效。

模型或参考	Dev 成功/100	Test 成功/100	有效更新
共同 64 题适配起点	41	31	继承 24 次
完整教师 SFT	82	72	300
普通 RLOO（单 seed）	44	34	16
sham（单 seed）	41	31	12
M3（单 seed）	41	32	12（局部项全零）
固定检索，共同模型	55	42	无新增训练
给正确事实，共同模型（特权诊断）	44	56	无新增训练

已有结果	能支持	不能支持
SFT 82/72	任务可学习，demo 可用	SFT 胜过 RL：两者监督量和起点都不同
RL 臂与起点差 0～3 题	这个训练量下没有可见的学习增量	RL 或 credit 的上限
M3 的 13 条局部支持差值全零	这套干预没有产生训练信号	非零 credit 训练后失败
强 SFT 新 Train 32 题 × 4：90/128 成功，8 组混合	还有未解决的任务和采样差异	这些差异能被 RL 学到
信息遮蔽探测：业务正确 18/24 → 12/24，调用 6.00 → 7.25	信息缺失会影响结果和恢复成本	动作 advantage，或 credit 的学习收益

另外，Brief v0.3 和 v0.4 都在 2026-10-30 发布，v0.4 改回 RL 的依据是研究定位的选择，并没有新增实验证据。证据基础与 CONCLUSION-1 建议弱化 credit 时相同。

三个最可能让方向走不通的问题

按致命程度排序：RL 可能学不动，任务可能没有可分配的决策，方法可能既证不出也说不出新意。 前两个否定当前任务上的研究问题，第三个否定论文价值。

问题一：普通 RL 可能学不动，而且任务有免费教师

- **没有从强 SFT 出发的 RL 数据。** 财报任务的 RL 臂都从 41/100 的弱起点出发，强 SFT 探测那轮 actor 更新为 0。
- **已有 RL 与没训练几乎没有区别。** RLOO 相对起点只多 3 题，sham 和 M3 在 Dev 上没有变化。
- **训练量差几个数量级。** M3 的 48 条父轨迹做 12 次更新，平均每次 4 条；RLOO 整臂按 token 反推约 64 条。BPO 每步用 128 题 × 8 条，共 3000 步；ASCT 按其协议算约 1500 次更新。任务不同无法精确比较，但现有 RL 还算不上一次学习测试。
- **有效信号可能更少。** 强 SFT 上只有 8/32 组成败混合。如果一次更新只看一题 × 4 条，约 3/4 的更新 RLOO 优势全为零。这一点要对照代码确认。
- **评审人会问为什么不继续用教师。** 任务的教师轨迹是现成的，而 SFT 只跑了一轮 300 次更新。多跑几轮可能就吃掉 RL 的提升空间。

问题二：任务可能没有可分配的决策，当前估计器也算不过账

- **完整成功几乎等于指标算对。** Dev 指标正确 82、成功 82；Test 指标正确 72、成功 72。强 SFT 之后，任务基本退化成带后处理的 FinQA 数值问答。

- **路径几乎固定。** 共同成功的轨迹都是 6 次调用，上限 10 次并不紧。只有人为遮蔽时才升到 7.25 次，所以自然轨迹里的核验和恢复可能很少。
- **能靠采样差异改进的失败有限。** 从 90/128 和 8 个混合组反推，38 条失败中有 16～28 条落在四条全败的题上。这些题拿不到 RLOO 信号。
- **每次只覆盖少数步骤。** 均匀 p=.12、每父迹最多一个 anchor、约 6 步，只覆盖约 9% 的步骤。
- **n=2 的 baseline 噪声比 RLOO 大。** 成功率 0.7 时，两条 MC 的附加噪声为 0.105，每组 4 条的 RLOO 为 0.070。V(h) 要偏离题目均值约 0.19 以上才划算。

预算账是这样的。动作无关的 baseline 不改变期望梯度，只能降方差，而辅助续写挤占了父轨迹。sham 实测父轨迹 token 少 24.5%，按 METHOD 参数估算相当于多花 73%。所以梯度噪声至少要降 25%～42% 才能回本。在 9% 的覆盖率下，选中步骤的噪声占比要达到平均的 2.7～4.7 倍才有可能。

问题三：方法缺少差异点，当前评估规模也证不出来

最近邻比 Brief 列的更密，TRACE、BPO、IGRPO、DEEP-GRPO 都不在 Brief 的表里。

工作	分配依据	与我们的关系
ASCT	均匀、UCT、含成本感知的 AgentUCT	最直接的对手，已包含成本感知
TRACE	最可能产生成败混合的 prompt 和前缀	已覆盖工具回合级预算分配
BPO	策略熵	已与均匀调度做消融，并有 VinePPO 对照
APPO	分支分数	已覆盖细粒度的分支选点
IGRPO	信息增益	已覆盖自适应扩展预算
DEEP-GRPO	可恢复性与学习价值	已覆盖从失败轨迹分支

我们的候选是手工阶段权重（.2/2/1/.4/2.5），METHOD 自己也说它不是新算法。这些权重还与当前任务绑定，很难推广到别的环境。

分配本身的效应也可能很小。ASCT 的 AgentUCT 对均匀只差 0.0041 ± 0.0116，方向随 seed 翻转；TRACE 对随机分配在不同预算下只多约 1 个准确率点。ASCT 还显示动作价值比 VinePPO 式状态价值高 0.0248，而我们用的正是状态价值。

方向上的改动

研究主题仍是工具 Agent 的 RL，但验证顺序要反过来：先证明有学习增量，再谈预算怎么分配。 下表是建议的 Brief 改动。

项目	现在（v0.4）	建议	理由
主问题	预算分配（RQ2）是首个候选	RQ3 学习收益先行，RQ2 作为条件性问题	没有学习信号时，分配差异无法被读出
对照基准	普通终局 RL 与 MC 对照	增加等时长的继续 SFT	教师现成，评审人一定会问
预算的含义	固定 token 上限	把预算当自变量，报告质量随 token 的曲线	上限是自设的，不是真实约束；效率曲线更可比
任务	财报条件委托四段链	增加决策更多的改造任务，原任务保留作对照	强 SFT 后成功几乎等于指标算对，路径固定
泛化证据	只有金融环境	增加一个最近邻也用的公开基准，如 HotpotQA	自建环境无法和已有工作直接比较
预期贡献	预算分配原型	暂不承诺，等数据决定	最近邻已覆盖分支选点和成本感知

可能的差异点（假设，尚未完成查新）： 与其再提一种分配规则，不如回答“额外续写在什么条件下根本不值得花”。具体做法是给出一个训练前就能测的回本条件，由覆盖率、每点样本数、挤占比例和任务的价值曲线决定，再用多个任务验证它能否预测训练后的收益。如果成立，金融任务上的负结果也会变成有用的证据。它能否成为贡献，取决于实验结果和后续查新。

换方向的条件： 如果 RL 在充足训练量下仍学不动，就停止在这个任务上投入 credit。CONCLUSION-1 提出的“核验与定向修复”不是稳妥的退路：它没有 demo，还要面对 SAG、CRITIC 等已有工作，需要重新评估。

方法上的改动

核心改动是把训练量提高约 50 倍，并把 n=2 和手工权重从预设变成待测变量。 其中父轨迹总量从约 64 条升到 3200 条。

环节	现在	改为	理由
RL 起点	共同 64 题适配模型（41/31）	强 SFT（82/72）	与 Brief 的目标一致，它至今没被测过

环节	现在	改为	理由
每次更新样本	约 4 条（反推）	32～64 条，来自多道题	单题更新大多没有成败差异
单臂总量	约 64 条，上限 250 万 token	约 3200 条，约 8300 万 token	先让学习曲线出现，再比较方法
学习率	材料未说明	扫 3 档	否则学不动可能只是学习率错了
每点续写数 n	固定 2	由价值曲线和梯度对比确定，测 2、6、16	VinePPO 默认 K=9，ASCT 用 B=12，BPO 实测 K=4～8
每父迹 anchor 数	最多 1 个	允许多个，作为对比条件	覆盖率 9% 很难回本
辅助续写用途	只估计 V，不进 actor	增加“也用于更新”的对比条件	sham 有 27% 的 token 没有用于更新；需同时分析 baseline 独立性
分配规则	手工阶段权重	与均匀、策略熵、TRACE 式规则对比，并用事后最优作上界	先判断分配是否有空间，再判断手工权重是否有价值
对照臂	RLOO 与 MC	增加等时长继续 SFT	回答“为什么要用 RL”
评估规模	Dev 100 题	324 题筛选，1000 题对照，2500 题终点	拿到能测出目标差异的功效
重复次数	单 seed	方法主张至少 3 个 seed	分配类效应比 seed 波动小

回本条件如下。挤占比例 c 是辅助续写 token 与父轨迹 token 之比，σ^2 是每条轨迹的梯度噪声，前提是总预算不变且 baseline 不改变期望梯度：

$$\frac{\sigma'^2}{\sigma^2} \le \frac{1}{1+c} \quad\Longleftrightarrow\quad \text{梯度噪声降幅} \ge \frac{c}{1+c}$$

这是理想化的粗算，没有计入 PPO clipping、优势白化和长度归一化。它的用途是决定优先测什么，最终以实测为准。DEEP-GRPO 也提到分散采样会让局部 baseline 不稳定，方向与这里的担心一致。

保持不变的部分： reward 和验证器不因方法效果放宽；辅助采样不读取答案；局部估计误差下降不能代替训练后策略的证据；新 100 题 Test 在方案冻结前不访问。

实验设计

按单张 H100 串行估算，五个阶段共约 8 天。 它们按依赖顺序排列，前一阶段的结果决定下一阶段跑什么。时间都是从材料速率反推的，阶段 0 实测后要重排。

阶段	实验	条件与对照	规模	GPU 时间（估）	回答什么
0 准备	扩任务池，测实际吞吐	至少 2500 题未用题，尽量来自不同报告	以 CPU 为主	约半天	后面的规模是否可行
A1 价值曲线	已有 128 条父轨迹，每步续写 16 条	不训练	约 2.4 亿 token	6 小时	V 在哪些步骤变化
A2 梯度对比	同一批数据	RLOO、MC n=2/6/16、续写也用于更新；各分配规则	不新增采样	2 小时	相同 token 下谁的梯度噪声最低
A3 过拟合	8 个混合题，每次 32 条，20 次更新	第 0/10/20 次更新评估	约 2600 万 token	1.5 小时	RL 链路能否学会见过的题
A4 学习率扫描	RLOO，3 档学习率，各 1600 条	与强 SFT 对比	约 1.2 亿 token	9 小时	能否泛化到新题
A5 继续 SFT	现有 800 题再跑 3 轮	在 324 题上与 A4 同评	约 6100 万输入 token	4 小时	监督学习还有多少空间
B 学习对照	RLOO、均匀 MC、继续 SFT，各 3 个 seed	同一强 SFT，1000 题评估	RL 每次 3200 条	约 2.2 天	credit 是否有独立收益
C 分配对照	策略熵、TRACE 式、手工权重，各 3 个 seed	连同 B 的均匀 MC，2500 题终点评估	评估共约 9 亿 token	约 3.3 天	预算分配是否有增量
D 公开基准	胜出方法与对照上 HotpotQA	视 C 的结果而定	待定	剩余时间	效果能否离开金融任务

关键设计的理由

- **先测价值曲线再训练。** 它不需要训练，却能直接回答“有没有可分配的决策”，还能给后面所有分配规则提供同一份评价数据。
- **梯度对比不含训练随机性。** 把每条轨迹的梯度投影到固定的随机方向，计算每 token 的信噪比，用 bootstrap 给出区间。n=2 和 n=6 从 16 条续写中抽取，其余续写作参考。
- **过拟合测试用来排除接线或学习率问题。** 这 8 题是按“混合”挑出来的，有回归均值的风险，所以第 0 次基线必须重新采样。
- **继续 SFT 必须是对照而不是参考。** 两臂从同一强 SFT 出发，给相同训练时长，这样才能回答 RL 是否值得。
- **每次更新都记录诊断量。** 包括非零优势占比、KL、梯度范数、实际 token 和 GPU 时长。没有效果时，这些数据能区分是没有信号还是步长太小。

数据分配

数据	用途	约束
现有 800 题 Train	SFT 与 RL 训练	已暴露
224 题未用新 Train + 旧 Dev 100 题，共 324 题	阶段 A 的筛选	用后视为已接触，不再作结论证据
新扩任务池（目标 ≥ 2500 题）	阶段 B 和 C 的评估	按报告分组统计，防止同报告题目虚增样本量
未评估的新 100 题 Test	最终复核	方案冻结前不开

改造任务的并行准备

阶段 A 期间并行准备改造任务，这样任何一项没过线，GPU 都能直接切过去。改造包括三项：

1. 工具调用上限从 10 收紧到 7 左右，让核验和恢复真正占用预算。
2. 用自然工具故障和证据冲突替代人为遮蔽。
3. 让任务需要多份证据，最优路径取决于工具实际返回什么，教师难以直接给出固定路径。

改造任务要先跑 A1，确认至少两个步骤有价值变化，再进入训练。任务在比较方法前冻结，不能根据方法效果再调。

实验如何验证方向

每个实验对应一个能被否定的方向判断，通过线在看到结果前定稿。 关卡不是为了省资源，而是为了不把 H100 花在读不出结论的对照上。下图的先后是判断顺序，不是运行顺序。

每一关没过都有去处，全部通过才进入论文主张



决策流程 · 5 个关卡，每关有明确去处

测试的判断	实验	成立时说明	不成立时说明
RL 能从强 SFT 继续学	A3、A4	有学习信号，其他比较才有意义	当前设置下 RL 不是有效杠杆
RL 比继续用教师划算	A5	这个任务确实需要 RL	需要改成教师难以覆盖的任务
任务里有可分配的决策	A1	预算分配有讨论空间	任务实际上是单点问答，应改任务
额外续写能回本	A2	值得进入训练对照	应改估计器或其样本用法
Credit 有独立学习收益	B	RQ3 得到支持	局部信号没有转化为策略收益
分配有增量且有差异点	C、D	RQ2 得到支持，可写方法主张	收窄成果定位，不声称分配有效

需要多少题才测得出

这决定了各阶段的评估规模。下表假设两个模型在 20% 的题上结果不同，双侧 5%、功效 80%，按题目独立计算，尚未计入 seed 方差和同报告相关性。

配对题数	能测出的最小差异	用在哪里
100	约 12.5 个百分点	现有 Dev，不足以下结论
324	约 7 个百分点	阶段 A 筛选
1000	约 4 个百分点	阶段 B
2500	约 2.5 个百分点	阶段 C
15700	约 1 个百分点	当前任务池大概率做不到

最后一行很关键。如果分配效应和 TRACE 报告的一样只有约 1 个点，即使有效也很难在成功率上证明。所以阶段 C 还要报告达到相同质量所需的 token，而不只是终点成功率。

其中 324 题的通过线定为 7 点，是因为更小的差异在这个规模下无法可靠测出。没达到 7 点不等于 RL 无效，只是它不足以占用后续的 GPU 时间。

估算假设与未核实事项

本报告的数字用于决定实验顺序，不是结论。 本评审只读了 5 份项目材料和一份旧状态页，没有看到代码和三步计划。

需要先确认的事项：

- [ ] 对照代码确认 RL 每次更新的样本构成（现在是从 48 条/12 次反推的约 4 条）以及学习率
- [ ] 确认 256 题新 Train 中有 224 题确实未被使用，并检查与三步计划有无冲突
- [ ] 实测 H100 吞吐，并测试两个进程能否同跑而不互相拖慢
- [ ] 用现有任务构造规则统计 FinQA 能产出多少新题，是否够 2500 题
- [ ] 对“回本条件”在 PPO 实际更新下的形式做分析，并做针对性查新

主要估算假设：

数字	来源或假设	可能的偏差
SFT 约 33 万 token/分钟	2032 万输入 token，61.9 分钟	包含加载时间
评估约 50～80 万 token/分钟	从 Test 阶段约 30 分钟反推	评估条数是推断的，偏差可能较大

数字	来源或假设	可能的偏差
每条轨迹约 2.6 万 token，续写约 1.8 万	128 父轨迹与 16 条续写的 token 数	改造任务上会变
RL 更新速度按 SFT 速度估算	本评审的假设	多个 epoch 会明显拉长 B、C
每条父轨迹约 6 步	材料中 311 请求/48 父轨迹	影响覆盖率的粗算
两模型 20% 题结果不同	本评审的假设	差异更大时需要更多题

文献方面，本评审核对的是相关章节而不是全文，其中多数是预印本。BPO 的实验设置有算不拢的数字（1+4×3=13 条再下采样），引用前要读全文。最近邻列表不是完整查新，提出任何首创性主张前都要再查一次。会议日期来自第三方追踪器，需以官方公布为准。

参考文献

项目材料：`D:\cursorprojects\蓝天鸣的科研材料\` 下的 RESEARCH_BRIEF(1).md、METHOD.md、CONCLUSION.md、CONCLUSION-1.md、paired_demo.md；`1\` 子目录中的旧 CURRENT_STATUS.md。

- ASCT: Attentive Search over Counterfactual Trees
- TRACE: A Unified Rollout Budget Allocation Framework
- BPO: Branching Policy Optimization
- IGRPO: Information Gain-based Rollout Policy Optimization
- DEEP-GRPO: Deep Dense Exploration
- APPO: Agentic Procedural Policy Optimization
- VinePPO: Refining Credit Assignment
- AdaStep: Adaptive Step Credit Weighting
- SAG: Selective Critique for Cost-Aware LLM Agents
- ICML 2027 日期追踪（非官方）