交易 Agent 信用分配项目：最新执行计划

依据：CURRENT_STATUS（核对至 2026-10-21）、两轮合作者讨论 | 整理日期：2026-10-22

一、当前共识

1. **最大的缺口是学习收益证据。**旧 M2（按动作族池化）已做过完整训练对照，没有建立优势；同前缀方案目前只证明了“某些收缩估计的离线误差更小”，还没有证明“用它训练，策略会学得更好”。
2. **新颖性要以最近邻为准重新界定。**AdaStep（2026-10）已经研究过按状态信噪比自适应收缩步级 credit；主动从同一状态分支续写，也有 VinePPO 等先例。“自适应 α”和“主动分支”本身都不能作为卖点。
3. **研究的中心问题改为“可比样本从哪里来、为它花的 token 是否值得”**，作为待验证的问题，不作为提前确定的论文卖点。
4. **证据边界不变。**已有结果都来自已接触的 Train 开发窗口，属于探索性证据；Brief 尚未签字，不等于此前看过的结果可以重新算作预注册验证。正式 Valid / Final OOS 保持关闭。

二、研究问题（待验证）

在持仓与风险历史使可比状态稀缺的交易任务中，**相同计算预算**用于增加普通轨迹，还是用于同前缀分支，能获得更有效的信用信号和学习收益？

三、最近邻方法对照

方法	可比样本从哪里来	信用信号	额外采样
VinePPO	从中间状态额外续写多次	用蒙特卡洛续写估计状态价值，替代 critic	有
GiGPO	在自然采样的轨迹中寻找相同环境状态（不要求同一动作重复）	同状态下不同动作的组内相对优势，叠加轨迹级优势	无
AdaStep	同 GiGPO 的状态分组	步级优势乘以按状态估计的自适应权重 $w^*(s) = \mathrm{Var}_a[Q] / (\mathrm{Var}_a[Q] + \mathrm{E}_a[\mathrm{Var}(R\|s,a)])$；无法估计的组回退到默认权重	无
本项目	从同一前缀主动分支，采样不同具体订单并各自续写	具体订单残差经收缩后，在 GAE 之后、白化之前叠加到 StepPO 优势上	有（必须计入成本）

口径说明：旧配置后期，192 个状态中有同状态同伴的为 21 个，同状态且同订单的为 10 个。10/192 不等于 GiGPO 的适用率，也不等于 AdaStep 可估权重的组数；二者的覆盖率需要按各自定义另算。

四、执行步骤

第 1 步　补清最近邻差异

- 填写 PAPER_MATRIX：VinePPO、GiGPO、AdaStep，以及树搜索类、分段估计优势类方法；按“可比样本来源、信用粒度、是否需要 critic、是否额外采样、适用环境”逐列对照。
- 用现有轨迹，按 GiGPO 和 AdaStep 各自的定义计算它们在本环境中的覆盖率。
- 明确写出：本项目在验证什么，不声称什么。

第 2 步　离线权重诊断（与训练接线并行，不阻塞启动）

- 利用现有 EST/REF 中同状态、同订单的重复续写，估计动作内波动和动作间差异。
- **估计与检验分开**：用 EST 估计权重，用 REF 检验效果，同一批 REF 不两头兼任。
- **扣除有限样本误差**：动作均值的离散程度要先减去抽样方差（约为方差 ÷ 样本数），剩余部分才算作信号。
- **不直接套用论文比值**：本项目的估计量经过具体订单池化和四槽均值中心化，噪声结构和单条轨迹回报不同。
- **定位**：真正有动作分歧的支持状态只有 8 个，结果只作为探索性诊断，用来确定训练对照的参数范围；不称“最优 α”，也不据此宣称交易环境的信噪比与其他任务不同。

第 3 步　冻结对照方案（跑任何训练对照之前）

- **主指标**：依据开发数据的功效分析，结合研究目标选定；定下后不再更改。
- **预算**：按生成 token 对齐；父轨迹、分支、后续续写的全部请求和 token 都计入成本。
- **配对方案**：配对窗口、多个训练 seed，尽量使用公共随机数。公共随机数用于降低比较方差，但策略分叉后同一 seed 不保证有效降低方差，因此仍需报告不确定性。
- **判断规则**：事先写明“优于、无法区分、劣于”各自对应的后续决定。
- 窗口 × seed 不当作独立样本；增加同窗口状态不能代替日期泛化。

第 4 步　小规模学习对照

候选分组如下，冻结时按预算取舍（例如只保留一档 α）：

组	预算用于	信用信号	回答的问题
零基线（M1）	普通轨迹	不加额外信号	共同基线
原生 AdaStep	普通轨迹（同预算下采样更多）	GiGPO 分组 + 自适应权重	不分支时能达到什么水平
分支 + 固定 α（plain）	同前缀分支	同 α，不按具体订单池化	与 exact 对比，区分收缩强度和具体订单池化的作用
分支 + 固定 α（exact）	同前缀分支	按具体订单池化后收缩	当前主候选
分支 + AdaStep 式权重	同前缀分支	用权重公式替代固定 α	权重估计本身是否有用

“原生 AdaStep”与“分支数据上的 AdaStep 式权重”要区分清楚：后者检验权重是否有用，前者才有助于回答额外分支是否值得成本。

第 5 步　根据结果决定后续投入

- **分支方案在同预算下更好**：扩大 seed 和窗口，按冻结规则开启 Valid；再考虑研究自适应权重。
- **动作分歧不足、信号太稀**：有针对性地补共同 SFT（扩大股票和仓位覆盖），一次只改一处。
- **分支不划算或无法区分**：整理诊断性结论。能支持的范围是：哪些分组条件会混淆状态与动作、在什么条件下收缩有帮助；不扩展为“细粒度 credit 救不了交易 RLVR”。

五、保留的纪律与可以减轻的部分

必须保留	可以减轻
共同初始化；全部采样成本核算；失败轨迹保留、不补零；训练端不读 REF；数据隔离；Valid / Final OOS 保持关闭	开发阶段的重复审计和逐批收据，可在主结果出来后补齐

六、已撤回或修正的说法

以下是前两轮讨论中纠正过的说法，后续文档和对外表述不再使用：

原说法	修正后
“经验贝叶斯 α + 信噪比解释”可以作为卖点	AdaStep 已有相同思路，不作为贡献
原 M2 基本就是 GiGPO；exact 基本就是 VinePPO	原 M2 把持仓历史不同的轨迹放在一起比较，违反了 GiGPO 的同状态前提；VinePPO 估计的是状态价值，不是具体订单的相对优势
“市场噪声决定项目上限”	分支在固定历史行情上运行，回报差异来自后续策略采样、持仓变化和风险暴露；“高波动应收缩更多”只是待检验假设
AdaStep 在 WebShop、ALFWorld 上权重取 1 最好	那是无法估计权重的组回退到哪个默认值的比较；可估计的组仍使用自适应权重
用 AdaStep 公式算出来的就是最优 α	只是探索性诊断，见第 2 步
“状态难重复，所以改为主动分支”就是新贡献	只是线索；主动分支已有先例，贡献要由同预算对照结果支撑
不共用随机种子，训练对照就等于白跑	公共随机数是降低方差的工具，应尽量采用，但不是唯一条件

七、冻结前待定事项

- 第 4 步保留哪几组、保留哪一档 α
- 每组的 token 预算、训练 seed 数和窗口数（由功效分析确定）
- 主指标及“优于 / 无法区分 / 劣于”的判断阈值
- Brief 签字冻结

参考文献

- AdaStep: Adaptive Step Credit Weighting for Agentic Reinforcement Learning — https://arxiv.org/html/2610.03223
- VinePPO — https://arxiv.org/html/2410.01679v2
- GiGPO — https://arxiv.org/html/2505.10978v2